

二次规划.

1°. 基本形式.

$$\begin{aligned} \min \quad & \frac{1}{2} x^T Q x + c^T x \\ \text{s.t.} \quad & a_i^T x \leq b_i, \quad i=1 \dots m. \\ & a_i^T x = b_i, \quad i=m+1, \dots, m+l. \end{aligned}$$

例: 均值方差; 最小-最大; 点到平面的距离.

2°. 带线性约束的二次规划. (Q半正定).

$$(\bar{QP}) \quad \begin{cases} \min \quad \frac{1}{2} x^T Q x + c^T x \\ \text{s.t.} \quad Ax = b. \end{cases} \quad A_{m \times n}, \quad r(A) = m.$$

1). 消去法. A 分块为 $A = (B, N)$. B 可逆.

$$(B, N) \begin{pmatrix} x_B \\ x_N \end{pmatrix} = b \quad \text{可化为} \quad Bx_B + Nx_N = b.$$

$$x_B = B^{-1}b + B^{-1}Nx_N.$$

$$x = \begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix} + \begin{pmatrix} B^{-1}N \\ x_N \end{pmatrix}.$$

$$= \underbrace{\begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix}} + \begin{pmatrix} B^{-1}N \\ E_{n-m} \end{pmatrix} x_N.$$

记 $Z = \begin{pmatrix} B^{-1}N \\ E \end{pmatrix}$, 可知 Z 的列为 $Ax=0$ 的基础解系, 即 A 的零空间的的一组基.

定理 1. 若 $Z^T Q Z$ 正定, 则 (\bar{QP}) 有唯一解.

(两种方法的比较).

2). KKT法:

因(QP)为线性约束的二次规划. 则 $KKT \Leftrightarrow$ 全局最优解.

$$\begin{cases} Qx + c + A^T \lambda = 0 \\ Ax = b \end{cases} \quad \text{即} \quad \begin{cases} Qx + A^T \lambda = -c \\ Ax = b. \end{cases}$$

$$\text{即} \quad \begin{pmatrix} Q & A^T \\ A & 0 \end{pmatrix} \begin{pmatrix} x \\ \lambda \end{pmatrix} = \begin{pmatrix} -c \\ b \end{pmatrix}.$$

解方程组即可!

3). 带不等式约束的二次规划. (Q 半正定, b).

$$(QP) \quad \begin{cases} \min \frac{1}{2} x^T Q x + c^T x \\ \text{s.t. } a_i^T x \leq b_i, i=1 \dots m. \text{ "I"} \\ a_i^T x = b_i, i=m+1, \dots, m+l. \text{ "E"} \end{cases}$$

1). 分析: 全局解 \Leftrightarrow KKT 条件.

2). 设 x^* 为 (QP) 的最优解, 记 $I(x^*)$ 为 x^* 的有效指标集,

$$\text{则 } x^* \text{ 为 } \begin{cases} \min \frac{1}{2} x^T Q x + c^T x \\ \text{s.t. } a_i^T x = b_i, i \in I(x^*) \\ a_i^T x = b_i, i=m+1 \dots m+l. \end{cases} \text{ 的解.}$$

证明: x^* 是 QP 的最优解, $\Rightarrow x^*$ 满足 KKT 条件.

即存在 λ 使得

$$\begin{cases} Qx^* + c + \sum_{i=1}^{m+l} \lambda_i a_i = 0 \\ \lambda_i \geq 0, i=1 \dots m, \\ \lambda_i (a_i^T x^* - b_i) = 0, i=1 \dots m, \\ a_i^T x^* \leq b_i, i=1 \dots m. \quad a_i^T x^* = b_i, i=m+1, \dots, m+l \end{cases}$$

因此 $Qx^* + c + \sum_{i \in I(x^*) \cup E} \lambda_i a_i + \sum_{i \in I \setminus I(x^*)} \lambda_i a_i = 0$ $Ax^* = b$

$$a_i^T x^* = b_i, i \in I(x^*) \cup E,$$

故, x^* 是 ... 的 KKT 点, 即全局解. \square

3) x^* 是 (QP) 的可行点. 若 x^* 是 (QP) 的最优解, x 为任意点,

若 $\lambda_i \geq 0, i \in I(x^*)$, 则 x^* 是 (QP) 的最优解!

证明: x^* 是 (QP) 的最优解, 则 x^* 满足 KKT 条件:

$$\begin{cases} Qx^* + c + \sum_{i \in E \cup I(x^*)} \lambda_i a_i = 0 \\ a_i^T x^* = b_i, i \in I(x^*) \\ a_i^T x^* = b_i, i \in E, \end{cases}$$

于是 $\lambda_i \geq 0, i \in I(x^*)$ x^* 是 (QP) 的可行点.

则

$$\begin{aligned} & Qx^* + c + \sum_{i \in I \setminus I(x^*)} \lambda_i a_i \\ & \lambda_i \geq 0, i \in I \setminus I(x^*) \\ & \lambda_i (a_i^T x^* - b_i) = 0, i \in I \setminus I(x^*) \\ & \lambda_i (a_i^T x^* - b_i) = 0, i \in I \setminus I(x^*) \end{aligned}$$

4). 有效集合法 (通过一系列线性约束求解一般 QP).

已知 x' 是 (QP) 的可行点, 记 $I(x')$,

求解, $\min \frac{1}{2} x^T Qx + c^T x$ (KKT 法)

$$\text{s.t. } a_i^T x = b_i, i \in I(x') \cup E.$$

得 \hat{x}

判断: 若 $x' = \hat{x}'$, 则判断乘子 $\lambda_i, i \in I(x')$ 的符号:

1) 若 $\lambda_i > 0, i \in I(x')$, 则 x' 是 (QP) 的最优解; 终止;

2) 若某个 $q \in I(x'), \lambda_q < 0$, 则 $x^2 = x', I(x^2) = I(x') \setminus \{q\}$.

若 $x' \neq \hat{x}'$,

1) 若 \hat{x}' 是 (QP) 的可行解, 则 $x^2 = \hat{x}'$, 更新 $I(x^2)$;

2) 若 \hat{x}' 不是 (QP) 的可行解, 记 $d = \hat{x}' - x'$.

$$\text{令 } a_i^T(x' + \alpha d) \leq b_i, \quad i \in I \setminus I(x')$$



$$\text{即 } a_i^T x' + \alpha a_i^T d \leq b_i, \quad i \in I \setminus I(x')$$

$$\text{取 } \alpha^* = \min \left\{ \frac{b_i - a_i^T x'}{a_i^T d} \mid a_i^T d > 0, i \in I \setminus I(x') \right\}$$

$$= \frac{b_q - a_q^T x'}{a_q^T d}$$

$$\text{令 } x^2 = x' + \alpha^* d, \quad I(x^2) = I(x^*) \cup \{q\}$$

重新求解:

$$\min \quad \frac{1}{2} x^T Q x + c^T x$$

$$\text{s.t. } a_i^T x = b_i, \quad i \in I(x^2) \cup E.$$

有效集算法 framework.

Step 0: 选取 (OP) 的可行点 x^0 . 记其有效指标集为 $I(x^0)$. $k := 0$.

Step 1: 求解其约束问题

$$\min \frac{1}{2} x^T Q x + c^T x$$

$$\text{s.t. } a_i^T x = b_i, i \in I(x^k) \cup E.$$

得 \hat{x}^k ,

Step 2: 若 $x^k = \hat{x}^k$; 考虑 Lagrange 乘子 $\lambda_i, i \in I(x^k)$:

若 $\lambda_i \geq 0 \forall i \in I(x^k)$, 终止, x^k 为 (OP) 的最优解;

否则, $\lambda_p = \min \{ \lambda_i \mid i \in I(x^k) \}$,

令 $x^{k+1} = x^k$, $I(x^{k+1}) = I(x^k) \setminus \{p\}$. $k = k+1$, 转 Step 1;

Step 3: 若 $x^k \neq \hat{x}^k$, \hat{x}^k 可行, 则 $x^{k+1} = \hat{x}^k$, 更新 $I(x^{k+1})$.

$k = k+1$. 转 Step 1.

例). $x^{k+1} = x^k + \alpha_k d^k$, 其中 $d^k = \hat{x}^k - x^k$,

$$\alpha_k = \frac{b_p - a_p^T \hat{x}^k}{a_p^T d^k} = \min \left\{ \frac{b_i - a_i^T \hat{x}^k}{a_i^T d^k} \mid a_i^T d^k > 0, i \in I(x^k) \right\}.$$

令 $k := k+1$, 转 Step 1.

$$(1) \min f(x) = x_1^2 + x_2^2 - 2x_1 - 4x_2$$

$$\text{s.t. } x_1 + x_2 + 1 \leq 0.$$

$$-x_1 \leq 0$$

$$-x_2 \leq 0$$

$$\begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

$$x^0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

$$\text{解: Step 0: } x^0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, I(x^0) = \{2, 3\}.$$

$$\text{第一次迭代: 求解 } \min f(x) \text{ s.t. } -x_1 \leq 0, -x_2 \leq 0. \quad A = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}, b = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} 2 & 0 & -1 & 0 \\ 0 & 4 & 0 & -1 \\ -1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \lambda_1 \\ \lambda_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ 0 \\ 0 \end{pmatrix} \text{ 得 } \hat{x}^0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \lambda_1 = -2, \lambda_2 = -4.$$

$$\text{令 } x^1 = \hat{x}^0, I(x^1) = \{2, 3\} \setminus \{3\} = \{2\}.$$

$$\text{第二次迭代: 求解 } \min f(x) \text{ s.t. } -x_1 \leq 0. \quad A = (-1, 0), b = 0$$

$$\begin{pmatrix} 2 & 0 & -1 \\ 0 & 2 & 0 \\ -1 & 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \lambda_1 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ 0 \end{pmatrix} \text{ 得 } \hat{x}^1 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \lambda_1 = -2.$$

$$\text{由于 } \hat{x}^1 \text{ 不是可行点, } d = \hat{x}^1 - x^1 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}.$$

$$\text{计算 } \alpha = \min_{\substack{a^T d > 0 \\ i \in \{1, 3\}}} \frac{b_i - a_i^T x^1}{a_i^T d}$$

$$= \frac{1}{2}.$$

$$\text{故 } x^2 = x^1 + \frac{1}{2}d = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, I(x^2) = \{2\} \cup \{1\}.$$

$$\text{第三次: 求解 } \min f(x) \text{ s.t. } x_1 + x_2 \leq 1, -x_1 \leq 0. \quad \begin{pmatrix} 2 & 0 & -1 & -1 \\ 0 & 2 & 0 & -1 \\ -1 & 0 & 0 & 0 \\ -1 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \lambda_1 \\ \lambda_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ 0 \\ 0 \end{pmatrix} \quad \hat{x}^2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \lambda = \begin{pmatrix} 2 \\ 0 \end{pmatrix}.$$

完毕.

4. 目标函数非凸时 (Q 不定矩阵). (补充内容仅供参考).

$$(OP) \begin{cases} \min \frac{1}{2} x^T Q x + c^T x =: f(x) \\ \text{s.t. } a_i^T x - b_i \leq 0, i \in I \\ \quad \quad a_i^T x - b_i = 0, i \in E. \end{cases} S.$$

Q 不定矩阵, 非凸问题.

常用方法: 1) 分支定界"求全局最优解

2) 近似算法, 求亚稳定 (KKT 条件).

序列凸逼近方法, (Sequential convex approximation, SCA).

基本思想: 用一系列凸问题逼近 (OP) 问题.

如何构造凸近似问题?

由于 Q 不定, 则可分解为 $Q = P - N$, P, N 为半正定.

(比如特征值分解 或对角扰动法).

$$\text{则 } f(x) = \frac{1}{2} x^T P x + c^T x - \frac{1}{2} x^T N x.$$

(两个凸函数之差, 亦称为 D.C. 函数, difference of convex...).

取 $\bar{x} \in S$, 在 \bar{x} 处用线性近似代替非凸部分 $g(x) = \frac{1}{2} x^T N x$

$$L(x) = g(\bar{x}) + \nabla g(\bar{x})^T (x - \bar{x}).$$

$$= -\frac{1}{2} \bar{x}^T N \bar{x} - (N \bar{x})^T (x - \bar{x})$$

$$= -\bar{x}^T N x + \frac{1}{2} \bar{x}^T N \bar{x}.$$

得 \bar{x} 处的近似子问题 (凸二次规划).

$$(QP(\bar{x})) \quad \begin{cases} \min & \frac{1}{2} \bar{x}^T P \bar{x} + c^T \bar{x} - \bar{x}^T N \bar{x} + \frac{1}{2} \bar{x}^T N \bar{x} \\ \text{s.t.} & a_i^T \bar{x} - b_i \leq 0, i \in I \\ & a_i^T \bar{x} - b_i = 0, i \in E. \end{cases}$$

可用有效集法求解.

lemma: 若 \bar{x} 是 $(QP(\bar{x}))$ 最优解, 则 \bar{x} 是 (QP) 的 KKT 点.

证明: 由于 \bar{x} 是 $(QP(\bar{x}))$ 最优解,

则 KKT 条件成立:

$$\begin{cases} P\bar{x} + c - N\bar{x} + \sum_{i \in I \cup E} \lambda_i a_i = 0 \\ \lambda_i \geq 0, i \in I \\ \lambda_i (a_i^T \bar{x} - b_i) = 0, i \in I \\ a_i^T \bar{x} - b_i \leq 0, i \in I \\ a_i^T \bar{x} - b_i = 0, i \in E \end{cases}$$

上述也是 (QP) 的 KKT 条件, 故 \bar{x} 是 (QP) 的最优解.

SCA framework:

Step 0: 取可行点 x^0 . $\varepsilon > 0$. $k := 0$.

Step 1: 求解凸二次规划问题 $(QP(x^k))$.

得最优解 x^{k+1} ;

Step 2: 若 $\|x^k - x^{k+1}\| \leq \varepsilon$, 终止;

Step 3: $k := k+1$, 转 Step 1.

SCA方法的收敛性: 设 $\varepsilon = 0$,

1). 若 SCA 有限步终止, 则 x^k 为 (QP) 的 KKT 点;

2). 设 $\{\lambda^k\}$ 有界, λ^k 为 (QP(x^k)) KKT 乘子; 任意 $\{x^k\}$ 的聚点 x^* , 均为 (QP) 的 KKT 点.

证: 1) 由 lemma 可知.

2) x^{k+1} 是 (QP(x^k)) 的最优解, λ^k 为乘子, 则

$$(\#) \quad \begin{cases} Px^{k+1} + c - Nx^k + \sum \lambda_i^k a_i = 0 \\ \lambda_i^k \geq 0 \\ \lambda_i^k (a_i^T x^{k+1} - b_i) = 0, i \in I. \\ a_i^T x^{k+1} - b_i \leq 0, i \in I \\ a_i^T x^{k+1} - b_i = 0, i \in E. \end{cases}$$

任取聚点 x^* , $\{x^k\}$ 的子列收敛到 x^* , 仍记为 $\{x^k\}$.

由于 $\{\lambda^k\}$ 有界, 存在收敛子列, 记 $\lambda^k \rightarrow \lambda^*$.

当 $k \rightarrow \infty$,

$$(\#) \rightarrow \begin{cases} Qx^* + c + \sum \lambda_i^* a_i = 0 \\ \lambda_i^* \geq 0, i \in I \\ \lambda_i^* (a_i^T x^* - b_i) = 0, i \in I \\ a_i^T x^* - b_i \leq 0, i \in I \\ a_i^T x^* - b_i = 0, i \in E, \end{cases}$$

即 x^* 为 (QP) 的 KKT 点. 完毕.